Subscribe to DeepL Pro to translate larger documents.
Visit www.DeepL.com/pro for more information.

Pembelajaran Interaksi Tingkat Rentang untuk Ekstraksi Tiga Elemen Sentimen Aspek

Lu Xu [*1,2] **, Yew Ken Chia** [*1,2]**, Lidong Bing** [2]
[1] Universitas Teknologi dan Desain Singapura
[2] Akademi DAMO, Grup Alibaba
{xu_lu,yewken_chia}@mymail.sutd.edu.sg
l.bing@alibaba-inc.com

Abstrak

Ekstraksi Triplet Sentimen Aspek (ASTE) adalah subtugas terbaru dari ABSA yang menghasilkan triplet berupa target aspek, sentimen yang terkait, dan istilah opini yang sesuai. Model-model terbaru melakukan ekstraksi triplet secara end-to-end, namun sangat bergantung pada interaksi antara setiap kata target dan kata opini. Akibatnya, mereka tidak dapat bekerja dengan baik pada target dan opini yang mengandung beberapa kata. Pendekatan tingkat rentang yang kami usulkan secara eksplisit mempertimbangkan interaksi antara rentang keseluruhan target dan opini saat memprediksi hubungan sentimen mereka. Dengan demikian, pendekatan ini dapat melakukan prediksi dengan semantik rentang keseluruhan, memastikan konsistensi sentimen yang lebih baik. Untuk mengurangi biaya komputasi tinggi yang disebabkan oleh penomoran rentang, kami mengusulkan strategi pemangkasan rentang dua saluran dengan memasukkan pengawasan dari tugas Ekstraksi Istilah Aspek (ATE) dan Ekstraksi Istilah Pendapat (OTE). Strategi ini tidak hanya meningkatkan efisiensi komputasi tetapi juga membedakan rentang pendapat dan target dengan lebih tepat. Kerangka kerja kami secara bersamaan mencapai kinerja yang kuat untuk tugas ASTE serta ATE dan OTE. Secara khusus, analisis kami menunjukkan bahwa pendekatan tingkat rentang kami mencapai perbaikan yang lebih signifikan dibandingkan dengan baseline pada triplet dengan target atau opini multi-kata. ([1])

1 Pengantar

Analisis Sentimen Berbasis Aspek (ABSA) (Liu, 2012; Pontiki dkk., 2014) merupakan agregasi dari beberapa tugas analisis sentimen yang detail, dan berbagai subtugasnya dirancang dengan target aspek sebagai elemen dasar. Untuk contoh dalam

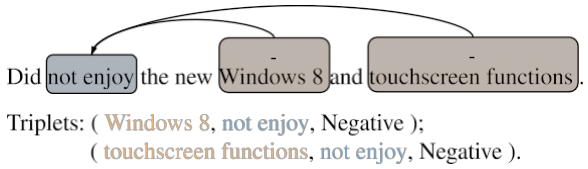

Gambar 1: Contoh ASTE. Rentang yang ditandai dengan warna oranye adalah istilah target, dan rentang berwarna biru adalah istilah opini. Tanda "-" di atas istilah target menunjukkan sentimen negatif.

Gambar 1, target aspek adalah *"Windows 8"* dan *"fungsi layar sentuh"*. Klasifikasi Sentimen Aspek (ASC) (Dong dkk., 2014; Zhang dkk., 2016; Yang dkk., 2017; Li dkk., 2018a; Tang et al., 2019) merupakan salah satu subtugas yang paling banyak dieksplorasi dalam ABSA dan bertujuan untuk memprediksi polaritas sentimen dari target aspek yang diberikan. Namun, tidak selalu praktis untuk mengasumsikan bahwa target aspek telah disediakan. Ekstraksi Istilah Aspek (ATE) (Yin et al., 2016; Li et al., 2018b; Ma et al., 2019) berfokus pada ekstraksi target aspek, sementara Ekstraksi Istilah Pendapat (OTE) (Yang dan Cardie, 2012; Klinger dan Cimiano, 2013; Yang dan Cardie, 2013) bertujuan untuk mengekstraksi istilah pendapat yang secara besar-besaran menentukan polaritas sentimen kalimat atau istilah target yang sesuai. Ekstraksi Triplet Sentimen Aspek (ASTE) (Peng et al., 2019) adalah subtugas terbaru yang diusulkan dalam ABSA, yang membentuk gambaran yang lebih lengkap tentang informasi sentimen melalui triplet yang terdiri dari istilah target aspek, istilah opini yang sesuai, dan sentimen yang diekspresikan. Untuk contoh pada Gambar 1, terdapat dua triplet: (*"Windows 8", "tidak menikmati"*, Negatif) dan (*"fungsi layar sentuh", "tidak menikmati"*, Negatif). Pendekatan awal untuk ASTE (Peng et al., 2019) adalah pipa dua tahap. Tahap pertama mengekstrak istilah target dan sentimennya melalui skema penandaan gabungan ([2]) serta istilah pendapat dengan stan-

* Kontribusi yang sama. Lu Xu dan Yew Ken Chia berada di bawah Program PhD Bersama antara Alibaba dan Universitas Teknologi dan Desain Singapura

iversity of Technology and Design.

[1] Kami membuat kode kami tersedia secara publik di https://github.com/chiayewken/Span-ASTE.

[2] Misalnya, tag gabungan "B-POS" menandakan awal

Prosiding Pertemuan Tahunan ke-59 Asosiasi Linguistik Komputasional dan Konferensi Bersama Internasional ke-11 tentang Pemrosesan Bahasa Alami, halaman 4755–4766
1–6 Agustus 2021. ©2021 Asosiasi Linguistik Komputasional

dard BIOES [3] tags. Tahap kedua kemudian menghubungkan istilah target dan opini yang diekstraksi untuk menentukan hubungan sentimen pasangan mereka. Kita tahu bahwa dalam ABSA, sentimen aspek sebagian besar ditentukan oleh istilah opini yang diekspresikan pada target aspek (Qiu et al., 2011; Yang dan Cardie, 2012). Namun, pendekatan pipa ini memutus interaksi dalam struktur triplet. Selain itu, pendekatan pipa umumnya mengalami masalah propagasi kesalahan.

Pendekatan end-to-end terbaru (Wu et al., 2020; Xu et al., 2020b; Zhang et al., 2020) dapat secara bersamaan mengekstrak istilah target dan opini serta mengklasifikasikan hubungan sentimen di antara keduanya. Salah satu kelemahan pendekatan ini adalah ketergantungannya yang tinggi pada interaksi antar kata untuk memprediksi hubungan sentimen pada pasangan target-opini. Perlu dicatat bahwa target aspek dan opini seringkali terdiri dari beberapa kata, yang menyumbang sekitar sepertiga dari triplet dalam dataset benchmark. Namun, metode sebelumnya (Wu et al., 2020; Zhang et al., 2020) memprediksi polaritas sentimen untuk setiap pasangan kata secara independen, yang tidak dapat menjamin konsistensi sentimen saat membentuk triplet. Akibatnya, keterbatasan prediksi pada triplet yang mengandung target atau opini multi-kata secara tidak terhindarkan merugikan kinerja ASTE secara keseluruhan. Untuk contoh pada Gambar 1, dengan hanya mempertimbangkan interaksi kata-ke-kata, mudah untuk salah memprediksi bahwa *"enjoy"* mengekspresikan sentimen positif terhadap *"Windows"*. Xu et al. (2020b) mengusulkan skema penandaan yang sadar posisi untuk memungkinkan model menghubungkan setiap kata dalam rentang target dengan semua rentang opini yang mungkin, yaitu interaksi antara kata aspek dan rentang opini (atau sebaliknya, interaksi antara rentang aspek dan kata opini). Namun, hal ini masih tidak dapat secara langsung memodelkan interaksi antara rentang target dan rentang opini secara keseluruhan.

Dalam makalah ini, kami mengusulkan model berbasis span untuk ASTE (Span-ASTE), yang untuk pertama kalinya secara langsung menangkap interaksi antar span saat memprediksi hubungan sentimen antara target aspek dan pasangan opini. Tentu saja, model ini juga dapat mempertimbangkan aspek atau opini berbasis kata tunggal dengan tepat. Model kami secara eksplisit menghasilkan representasi rentang untuk semua rentang target dan opini yang mungkin, dan hubungan sentimen pasangan mereka diprediksi secara independen untuk semua pasangan target dan opini yang mungkin. Metode berbasis rentang telah menunjukkan hasil yang menjanjikan Kinerja pada tugas-tugas lain, seperti resolusi coreference (Lee et al., 2017), penandaan peran semantik (He et al., 2018a), dan ekstraksi hubungan (Luan et al., 2019; Wadden et al., 2019). Namun, metode-metode ini tidak dapat diterapkan secara langsung pada tugas ASTE karena karakteristik spesifik tugas yang berbeda.

Kontribusi kami dapat dirangkum sebagai berikut:

- Kami menyesuaikan pendekatan tingkat rentang untuk secara eksplisit mempertimbangkan interaksi antar rentang pada tugas ASTE dan melakukan analisis mendalam untuk menunjukkan keefektifannya. Pendekatan kami secara signifikan meningkatkan kinerja, terutama pada triplet yang mengandung target atau opini multi-kata.

- Kami mengusulkan strategi pemangkasan rentang dua saluran dengan memasukkan pengawasan eksplisit dari tugas ATE dan OTE untuk mengurangi biaya komputasi tinggi yang disebabkan oleh penomoran rentang dan memaksimalkan peluang menggabungkan kandidat target dan opini yang valid.

- Model Span-ASTE yang kami usulkan secara signifikan outperform metode sebelumnya tidak hanya untuk tugas ASTE, tetapi juga untuk tugas ATE dan OTE pada empat dataset benchmark dengan encoder BiLSTM dan BERT.

2 Span-based ASTE

2.1 Formulasi Tugas

Biarkan $X = \{x_1, x_2, ..., x_n\}$ mewakili kalimat dengan n token, dan biarkan $S = \{s_{1,1}, s_{1,2},..., s_{i,j}, ..., s_{n,n}\}$mewakili himpunan semua rentang bernomor yang mungkin dalam X, dengan i dan j menunjukkan posisi awal dan akhir dari sebuah rentang dalam kalimat. Kami membatasi panjang rentang sebagai $0 \leq j - i \leq L$. Tujuan tugas ASTE adalah untuk mengekstrak semua triplet yang mungkin dalam X. Setiap triplet sentimen didefinisikan sebagai (*target, opini, sentimen*) di mana

sentimen $\in$ {*Positif, Negatif, Netral*}.

2.2 Arsitektur Model

Seperti yang ditunjukkan pada Gambar 2, Span-ASTE terdiri dari tiga modul: modul pengkodean kalimat, modul penyebutan, dan modul triplet. Untuk contoh yang diberikan, kalimat terlebih dahulu dimasukkan ke modul pengkodean kalimat untuk mendapatkan representasi tingkat token, dari mana kami memperoleh representasi tingkat rentang untuk setiap rentang yang terdaftar, seperti *"tidak menikmati"*, *"Windows 8"*. Kami kemudian mengadopsi tugas ATE dan OTE untuk mengawasi strategi pemangkasan rentang dua saluran yang diusulkan, yang menghasilkan target yang dipangkas dan

target span dengan polaritas sentimen positif.

[3]Skema penandaan umum untuk penandaan urutan, yang menandakan "awal, dalam, luar, akhir, dan tunggal" masing-masing.

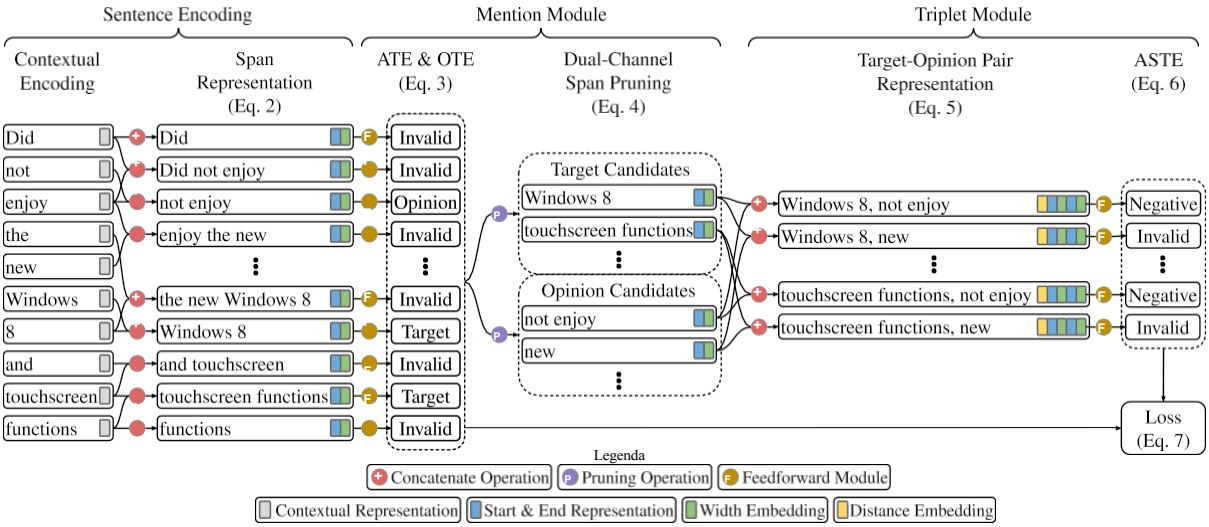

Gambar 2: Struktur model Span-ASTE.

Kandidat opini, seperti *"Windows 8"* dan *"tidak menikmati"* masing-masing. Akhirnya, setiap kandidat target dan kandidat opini dihubungkan untuk menentukan hubungan sentimen di antara keduanya.

2.2.1 Enkoding Kalimat

Kami menjelajahi dua metode enkoding untuk mendapatkan representasi kontekstual untuk setiap kata dalam kalimat: BiLSTM dan BERT.

BiLSTM Kami pertama-tama memperoleh representasi kata $\{\mathbf{e}_1, \mathbf{e}_2, \ldots, \mathbf{e}_i, \ldots, \mathbf{e}_n\}$ dari model GloVe yang telah dilatih sebelumnya dengan dimensi 300 (Pennington dkk., (2014) embeddings yang kemudian dikontekstualisasikan oleh lapisan LSTM dua arah (Hochreiter dan Schmid-huber, 1997). Token *ke-i* diwakili sebagai:

$$\mathbf{h}_i = [\overrightarrow{\mathbf{h}_i}; \overleftarrow{\mathbf{h}_i}] \quad (1)$$

di mana $\overrightarrow{\mathbf{h}_i}$ dan $\overleftarrow{\mathbf{h}_i}$ adalah keadaan tersembunyi dari for-LSTM maju dan mundur masing-masing.

BERT Metode enkoding alternatif adalah menggunakan model bahasa yang telah dilatih sebelumnya seperti BERT (Devlin dkk., 2019) untuk mendapatkan representasi kata yang kontekstual $\mathbf{x} = [\mathbf{x}_1, \mathbf{x}_2, \ldots, \mathbf{x}_n]$. Untuk kata-kata yang ditokenisasi menjadi beberapa potongan kata, kami menggunakan mean pooling untuk menggabungkan representasi mereka.

Representasi Rentang Kami mendefinisikan setiap representasi rentang rep-representasi $s_{i,j} \in S$ sebagai

$$\mathbf{s}_{i,j} = \begin{cases} [\mathbf{h}_i; \mathbf{h}_j; f_{lebar}(i,j)] & \text{jika BiLSTM} \\ [\mathbf{x}_i; \mathbf{x}_j; f_{lebar}(i,j)] & \text{jika BERT} \end{cases} \quad (2)$$

di mana $f_{lebar}(i, j)$ menghasilkan representasi fitur yang dapat dilatih untuk lebar rentang (yaitu, $j - i + 1$).

Selain konkatenaasi token awal, token akhir, dan representasi lebar, representasi rentang $\mathbf{s}_{i,j}$ juga dapat dibentuk melalui max-pooling atau mean-pooling di seluruh representasi token rentang dari posisi i hingga j. Hasil eksperimen dapat ditemukan dalam studi ablasi.

2.2.2 Modul Mention

Tugas ATE & OTE Kami menggunakan sub-tugas ABSA dari ATE dan OTE untuk mengarahkan strategi pemangkasan rentang dua saluran kami melalui skor rentang opini dan target yang diprediksi. Perlu dicatat bahwa istilah target dan istilah opini belum dipasangkan pada tahap ini. Modul mention mengambil representasi setiap rentang yang terdaftar $\mathbf{s}_{i,j}$ sebagai masukan dan memprediksi jenis mention

$m \in \{Target, Pendapat, Tidak\ Sah\}$.

$$P(\mathbf{m}|\mathbf{s}_{i,j}) = \text{softmax}(\text{FFNN}_m(\mathbf{s}_{i,j})) \quad (3)$$

di mana FFNN menandakan jaringan saraf feed-forward dengan aktivasi non-linier.

Target dan Pendapat yang Dipangkas Untuk kalimat X dengan panjang n, jumlah rentang yang terdaftar adalah $O(n^2)$, sementara jumlah pasangan yang mungkin antara semua rentang kandidat pendapat dan target adalah $O(n^4)$ pada tahap selanjutnya (yaitu, modul triplet). Oleh karena itu,

tidak praktis secara komputasi untuk mempertimbangkan semua interaksi pasangan yang mungkin saat menggunakan representasi rentang-pendekatan berbasis. Penelitian sebelumnya (Luan dkk., 2019; Wadden dkk., 2019) menggunakan strategi pemangkasan untuk mengurangi jumlah rentang, tetapi mereka hanya memangkas rentang ke dalam satu kumpulan yang merupakan campuran dari berbagai jenis mention. Strategi ini tidak sepenuhnya mempertimbangkan

Kumpulan Data	Istirahat 14					Putaran 14					Istirahat 15						Istirahat 16					
	#S	# +	# 0	# -	#SW	#MW	#S	# +	# 0	# -	#SW	#MW	#S	# +	# 0	# -	#SW	#MW	#S	# +	# 0	# -	#SW	#MW
Kereta	1266	1692	166	480	1586	752	906	817	126	517	824	636	605	783	25	205	678	335	857	1015	50	329	918	476
Dev	310	404	54	119	388	189	219	169	36	141	190	156	148	185	11	53	165	84	210	252	11	76	216	123
Uji	492	773	66	155	657	337	328	364	63	116	291	252	322	317	25	143	297	188	326	407	29	78	344	170

Tabel 1: Statistik dataset. #S menandakan jumlah kalimat. #+, #0, dan #- menandakan jumlah triplet sentimen positif, netral, dan negatif masing-masing. #SW menandakan jumlah triplet di mana baik istilah target maupun istilah opini berupa rentang kata tunggal. #MW menandakan jumlah triplet di mana setidaknya salah satu dari istilah target atau opini berupa rentang kata ganda.

struktur dari sebuah triplet sentimen aspek sebagaimana adanya tidak
tidak mengenali perbedaan mendasar antara

Sebuah target dan istilah pendapat. Oleh karena itu, kami mengusulkan untuk menggunakan strategi pemangkasan dua saluran yang menghasilkan dua kumpulan aspek dan pendapat yang dipangkas secara terpisah.
ions. Hal ini meminimalkan biaya komputasi sambil memaksimalkan peluang untuk mencocokkan opini yang valid dan rentang target digabungkan. Calon pendapat dan target dipilih berdasarkan skor dari

jenis penyebutan untuk setiap rentang berdasarkan Persamaan 3:

$$\Phi_{target}(\mathbf{s}_{i,j}) = P(m = \textbf{target} \mid \mathbf{s}_{i,j})$$
$$\Phi_{pendapat}(\mathbf{s}_{i,j}) = P(m = \textbf{pendapat} \mid \mathbf{s}_{i,j}) \quad (4)$$

Kami menggunakan skor mention Φ_{target} dan $\Phi_{opinion}$ untuk memilih kandidat teratas dari rentang yang terdaftar dan memperoleh kumpulan kandidat target
$S^t = \{\ldots, \mathbf{s}^t_{a,b}, \ldots\}$ dan kumpulan kandidat opini
$S^o = \{\ldots, \mathbf{s}^o_{c,d}, \ldots\}$ masing-masing. Untuk mempertimbangkan pro-
jumlah kandidat yang proporsional untuk setiap kalimat,
jumlah rentang yang dipilih untuk kandidat target yang dipangkas dan kandidat opini adalah nz, di mana n adalah jumlah kalimat, panjang kalimat dan z adalah parameter ambang batas hiper. Perhatikan bahwa meskipun operasi pemangkasan mencegah aliran gradien kembali ke FFNN dalam mention
, yang sudah menerima pengawasan dari
tugas ATE dan OTE. Oleh karena itu, model kami dapat

dilatih end-to-end tanpa masalah atau ketidakstabilan.

2.2.3 Modul Triplet

Representasi Pasangan Pendapat Target Kami memperoleh representasi pasangan target-opini dengan mengkombinasikan
menggabungkan setiap representasi kandidat target $\mathbf{s}^t_{a,b} \in S^t$
dengan setiap representasi kandidat opini $\mathbf{s}^o_{c,d} \in S^o$:

$$\mathbf{g}_{\mathbf{s}^{t\,a,b},\mathbf{s}^{o}_{c,d}} = [\mathbf{s}^{t}_{a,b}; \mathbf{s}^{o}_{c,d}; f_{jarak}(a, b, c, d)] \quad (5)$$

di mana $f_{jarak}(a, b, c, d)$ menghasilkan embedding fitur yang dapat dilatih berdasarkan jarak (yaitu,
$min(|b - c|, |a - d|)$) antara target dan rentang opini
, mengikuti (Lee et al., 2017; He et al.,
2018a; Xu dkk., 2020b).

Klasifikasi Hubungan Sentimen Kemudian, kami menempatkan representasi pasangan rentang $\mathbf{g}_{\mathbf{s}^{t}_{a,b},\mathbf{s}^{o}_{c,d}}$ ke jaringan saraf feed-forward untuk menentukan probabilitas hubungan sentimen $r \in R = \{Positif, Negatif, Netral, Tidak\ Sah\}$

antara target $\mathbf{s}^t_{a,b}$ dan pendapat $\mathbf{s}^o_{c,d}$:

$$P(\mathbf{r} \mid \mathbf{s}^t_{a,b}, \mathbf{s}^{o}_{c,d}) = \text{softmax}(\text{FFNN}_r(\mathbf{g}_{\mathbf{s}^{t}_{a,b},\mathbf{s}^{o}_{c,d}})) \quad (6)$$

Invalid di sini menunjukkan bahwa pasangan target dan opini tidak memiliki hubungan sentimen yang valid.

2.3 Pelatihan

Tujuan pelatihan didefinisikan sebagai jumlah log-likelihood negatif dari modul mention dan modul triplet.

$$\mathbf{L} = -\sum_{\mathbf{s}_{i,j} \in S} \log P(m^*_{i,j} \mid \mathbf{s}_{i,j}) - \sum_{\mathbf{s}^t_{a,b} \in S^t, \mathbf{s}^o_{c,d} \in S^o} \log P(r^* \mid \mathbf{s}^t_{a,b}, \mathbf{s}^{o}_{c,d}) \quad (7)$$

di mana $m^*_{i,j}$ adalah jenis mention emas dari span $\mathbf{s}_{i,j}$,
dan r^* adalah hubungan sentimen emas dari target
dan pasangan rentang pendapat $(\mathbf{s}^t_{a,b}, \mathbf{s}^{o}_{c,d})$. S menunjukkan
($\mathbf{s}^t$ kumpulan rentang yang
terdaftar; S^t dan S^o adalah kandidat yang disaring
dan kandidat rentang pendapat.

3 Eksperimen

3.1 Kumpulan Data

Model Span-ASTE yang kami usulkan dievaluasi pada empat dataset ASTE yang dirilis oleh Xu et al. (2020b), yang mencakup tiga dataset di restoran do-
utama dan satu dataset di domain laptop. Versi pertama dataset ASTE telah dirilis
oleh Peng et al. (2019). Namun, ditemukan bahwa tidak semua triplet di anotasi secara eksplisit (Xu et al., 2020b; Wu et al., 2020). Xu et al. (2020b) memperbaiki dataset dengan triplet yang hilang dan menghapus triplet dengan sentimen yang bertentangan. Perlu dicatat bahwa ini

	Model	Sisa 14			Lap 14			Istirahat 15			Istirahat 16		
		P.	*R.*	F_1	*P.*	*R.*	F_1	*P.*	*R.*	F_1	*P.*	*R.*	F_1
BiLSTM	CMLA+ (Wang dkk., 2017)†	39,18	47,13	42,79	30,09	36,92	33,16	34,56	39,84	37,01	41,34	42,10	41,72
	RINANTE+ (Dai dan Song, 2019)†	31,42	39,38	34,95	21,71	18,66	20,07	29,88	30,06	29,97	25,68	22,30	23,87
	Li-unified-R (Li dkk., 2019)†	41,04	67,35	51,00	40,56	44,28	42,34	44,72	51,39	47,82	37,33	54,51	44,31
	Peng dkk. (2019)†	43,24	63,66	51,46	37,38	50,38	42,87	48,07	57,51	52,32	46,96	64,24	54,21
	Zhang dkk. (2020) *	62,70	57,10	59,71	49,62	41,07	44,78	55,63	42,51	47,94	60,95	53,35	56,82
	GTS (Wu dkk., 2020)*	66,13	57,91	61,73	53,35	40,99	46,31	60,10	46,89	52,66	63,28	58,56	60,79
	JET$^{o\,M=6}$ (Xu dkk., 2020b)†	61,50	55,13	58,14	53,03	33,89	41,35	64,37	44,33	52,50	70,94	57,00	63,21
	Span-ASTE (Kami)	72,52	62,43	**67,08**	59,85	45,67	**51,80**	64,29	52,12	**57,56**	67,25	61,75	**64,37**
BERT	GTS (Wu dkk., 2020)*	67,76	67,29	67,50	57,82	51,32	54,36	62,59	57,94	60,15	66,08	69,91	67,93
	JET$^{o\,M=6}$ (Xu et al., 2020b) †	70,56	55,94	62,40	55,39	47,33	51,04	64,45	51,96	57,53	70,42	58,37	63,83
	Span-ASTE (Kami)	72,89	70,89	**71,85**	63,44	55,84	**59,38**	62,18	64,45	**63,27**	69,45	71,17	**70,26**

Tabel 2: Hasil pada set uji tugas ASTE. † : Hasil ini diambil dari Xu et al. (2020b). * : Untuk perbandingan yang adil, kami mereproduksi hasil menggunakan kode implementasi dan konfigurasi yang dirilis oleh mereka pada set data ASTE yang sama
ASTE yang dirilis oleh Xu et al. (2020b).

Empat dataset acuan diperoleh dari Se-mEval Challenge (Pontiki dkk., 2014, 2015, 2016), dan istilah opini diambil dari (Fan dkk., 2019). Tabel 1 menampilkan statistik rinci.

3.2 Pengaturan Eksperimen

Saat menggunakan encoder BiLSTM, embedding kata GloVe yang telah dilatih sebelumnya dapat dilatih ulang. Ukuran hidden dari encoder BiLSTM adalah 300 dan tingkat dropout adalah 0,5. Pada pengaturan kedua, kami melakukan fine-tuning pada model BERT yang telah dilatih sebelumnya (Devlin dkk., 2019) untuk mengenkode setiap kalimat. Secara spesifik, kami menggunakan versi un-cased dari BERT$_{(base)}$.Model dilatih selama 10 epoch dengan pemanasan linier untuk 10% langkah pelatihan, diikuti oleh penurunan linier laju pembelajaran hingga 0. Kami menggunakan AdamW sebagai optimizer dengan laju pembelajaran maksimum 5e-5 untuk bobot transformer dan penurunan bobot 1e-2. Untuk kelompok parameter lainnya, kami menggunakan laju pembelajaran 1e-3 tanpa penurunan bobot. Panjang rentang maksimum L ditetapkan sebagai 8. Ambang batas pemangkasan rentang z ditetapkan sebagai 0,5. Kami memilih bobot model terbaik berdasarkan skor F$_{(1)}$pada set pengembangan, dan hasil yang dilaporkan adalah rata-rata dari 5 kali eksekusi dengan benih acak yang berbeda. ([4])

3.3 Garis dasar

Baselines dapat dirangkum menjadi dua kelompok: metode pipeline dan metode end-to-end.

Pipeline Untuk pendekatan pipeline yang tercantum di bawah ini, metode ini dimodifikasi oleh Peng et al. (2019) untuk mengekstrak istilah aspek bersama dengan sentimen terkait melalui skema penandaan bersama, dan Istilah opini dengan tag BIOES pada tahap pertama. Pada tahap kedua, target dan opini yang diekstraksi kemudian dipasangkan untuk menentukan apakah mereka dapat membentuk triplet yang valid. Perlu dicatat bahwa pendekatan-pendekatan ini menggunakan metode yang berbeda untuk memperoleh fitur pada tahap pertama. CMLA+ (Wang et al., 2017) menggunakan mekanisme perhatian untuk mempertimbangkan interaksi antara istilah aspek dan istilah opini. RINANTE+ (Dai dan Song, 2019) mengadopsi model BiLSTM-CRF dengan aturan yang diekstraksi untuk menangkap hubungan ketergantungan. Li-unified-R (Li dkk., 2019) menggunakan skema penandaan terpadu untuk mengekstrak istilah aspek dan sentimen terkait secara bersamaan. Peng et al. (2019) memasukkan informasi hubungan ketergantungan saat mempertimbangkan interaksi antara istilah aspek dan istilah opini.

End-to-end Metode end-to-end bertujuan untuk mengekstrak triplet lengkap secara bersamaan dalam satu tahap. Penelitian sebelumnya oleh Zhang et al. (2020) dan Wu et al. (2020) secara independen memprediksi hubungan sentimen untuk semua pasangan kata yang mungkin, sehingga mereka memerlukan heuristik dekodasi untuk menentukan polaritas sentimen keseluruhan dari sebuah triplet. JET (Xu dkk., 2020b) memodelkan tugas ASTE sebagai masalah prediksi terstruktur dengan skema penandaan yang sadar posisi untuk menangkap interaksi antara tiga elemen dalam sebuah triplet.

3.4 Hasil Eksperimen

Tabel 2 membandingkan Span-ASTE dengan model sebelumnya dalam hal Presisi (*P.*), Recall (*R.*), dan skor$_{F(1)}$pada empat dataset. Berdasarkan metrik F_1, model kami secara konsisten outperform model sebelumnya untuk both BiLSTM dan BERT sentence encoders. Dalam kebanyakan kasus, model kami secara signifikan outperform...

[4] Lihat Lampiran untuk pengaturan eksperimen lebih lanjut, serta hasil pengembangan pada empat dataset.

Melakukan metode end-to-end lainnya dalam hal presisi dan recall. Kami juga mengamati bahwa dua metode pipeline yang kuat (Li et al., 2019; Peng et al., 2019) mencapai hasil recall yang kompetitif, tetapi kinerja keseluruhan mereka jauh lebih buruk karena presisi yang rendah. Secara spesifik, dengan menggunakan encoder BiLSTM dan embedding GloVe, model kami mengungguli model pipeline terbaik (Peng et al., 2019) sebesar 15,62, 8,93, 5,24, dan 10,16 poin $F_{(1)}$pada empat dataset. Hasil ini menunjukkan bahwa pendekatan end-to-end kami dapat secara efektif mengenkode interaksi antara rentang target dan opini, serta mengurangi penyebaran kesalahan. Secara umum, metode end-to-end lainnya juga lebih kompetitif daripada metode pipeline. Namun, karena keterbatasan bergantung pada interaksi tingkat kata, kinerjanya kurang memuaskan dalam beberapa kasus, seperti hasil pada Lap 14 dan Rest 15. Dengan encoder BERT, ketiga model end-to-end mencapai kinerja yang jauh lebih kuat daripada versi berbasis LSTM mereka, yang konsisten dengan temuan sebelumnya (Devlin et al., 2019). Pendekatan kami mengungguli hasil terbaik sebelumnya GTS (Wu et al., 2020) sebesar 4,35, 5,02, 3,12, dan 2,33 poin $F_{(1)}$pada keempat dataset.

3.5 Eksperimen Tambahan

Seperti yang disebutkan dalam Bagian 2.2.2, kami menggunakan subtugas ABSA dari ATE dan OTE untuk mengarahkan strategi pemangkasan rentang kami. Untuk memeriksa apakah Span-ASTE dapat secara efektif mengekstrak rentang target dan rentang opini, kami juga mengevaluasi model kami pada tugas ATE dan OTE pada empat dataset. Tabel 3 menunjukkan perbandingan antara pendekatan kami dan metode sebelumnya GTS (Wu et al., 2020). ([5]) Tanpa pelatihan ulang atau penyesuaian tambahan, model kami dapat langsung menangani tugas ATE dan OTE, dengan peningkatan kinerja yang signifikan dibandingkan GTS dalam hal skor $F_{(1)}$pada kedua tugas tersebut. Meskipun GTS menunjukkan skor recall yang lebih baik pada dataset Rest 16, skor presisi yang rendah mengakibatkan kinerja $F_{(1)}$ yang lebih buruk. Kinerja keseluruhan yang lebih baik menunjukkan bahwa metode tingkat rentang kami tidak hanya menguntungkan ekstraksi triplet sentimen, tetapi juga meningkatkan ekstraksi istilah target dan opini dengan mempertimbangkan semantik setiap rentang utuh daripada mengandalkan heuristik dekodasi metode berbasis penandaan.

[5] Lihat Lampiran untuk statistik data target dan opini. Perlu dicatat bahwa model JET (Xu et al., 2020b) tidak dapat secara langsung menyelesaikan tugas ATE dan OTE kecuali evaluasi dilakukan berdasarkan prediksi triplet. Kami menyertakan perbandingan semacam itu dalam Lampiran.

Dataset	Model	ATE			OTE		
		P.	*R.*	F_1	*P.*	*R.*	F_1
Istirahat 14	GTS	78,12	85,64	81,69	81,12	88,24	84,53
	Kami	83,56	87,59	**85,50**	82,93	89,67	**86,16**
Lap 14	GTS	76,63	82,68	79,53	76,11	78,44	77,25
	Kami	81,48	86,39	**83,86**	83,00	82,28	**82,63**
Istirahat 15	GTS	75,13	81,57	78,21	74,96	82,52	78,49
	Kami	78,97	84,68	**81,72**	77,36	84,86	**80,93**
Istirahat 16	GTS	75,06	89,42	81,61	78,99	88,71	83,57
	Kami	79,78	88,50	**83,89**	82,59	90,91	**86,54**

Tabel 3: Hasil pengujian pada tugas ATE dan OTE dengan encoder BERT. Sebagai referensi, kami menyertakan hasil kerangka kerja RACL (Chen dan Qian, 2020) di Lampiran. RACL merupakan metode terdepan saat ini untuk kedua tugas tersebut. Namun, kerangka kerja mereka tidak mempertimbangkan hubungan pasangan antara setiap target dan opini, sehingga sulit untuk melakukan perbandingan yang sepenuhnya adil.

4 Analisis

4.1 Perbandingan Rentang Kata Tunggal dan Multi-kata

Kami membandingkan kinerja Span-ASTE dengan model sebelumnya GTS (Wu et al., 2020) untuk dua pengaturan berikut dalam Tabel 4: Single-Word: Baik istilah target maupun istilah opini dalam sebuah triplet berupa rentang kata tunggal, Multi-Word: Setidaknya salah satu dari istilah target atau opini dalam sebuah triplet berupa rentang kata ganda. Untuk pengaturan single-word, metode kami menunjukkan peningkatan konsisten dalam hal presisi dan skor recall pada empat dataset, yang menghasilkan peningkatan skor $F_{(1)}$. Ketika kami membandingkan evaluasi untuk triplet multi-word, model kami mencapai peningkatan yang lebih signifikan untuk skor $F_{(1)}$. Dibandingkan dengan presisi, recall kami menunjukkan peningkatan yang lebih besar dibandingkan dengan pendekatan GTS. GTS sangat bergantung pada interaksi pasangan kata untuk mengekstrak triplet, sementara metode kami secara eksplisit mempertimbangkan interaksi rentang-ke-rentang. Enumerasi rentang kami juga secara alami meningkatkan recall rentang multi-kata. Baik GTS maupun model kami menghadapi tantangan dengan triplet multi-kata, dan skor $F_{(1)}$mereka turun lebih dari 10 poin, bahkan lebih dari 20 poin untuk Rest 14. Seperti yang ditunjukkan dalam Tabel 1, dibandingkan dengan triplet kata tunggal, triplet multi-kata umum dan menyumbang sepertiga atau bahkan setengah dari dataset. Oleh karena itu, arah yang menjanjikan untuk penelitian masa depan adalah meningkatkan kinerja model pada triplet yang sulit tersebut.

Untuk mengidentifikasi area-area lain yang perlu ditingkatkan, kami menganalisis hasil untuk tugas ASTE berdasarkan apakah setiap triplet sentimen mengandung mode multi-

	Mode	Model	Istirahat 14			Lap 14			Istirahat 15			Istirahat 16		
			P.	*R.*	F_1	*P.*	*R.*	F_1	*P.*	*R.*	F_1	*P.*	*R.*	F_1
BERT	Kata Tunggal	GTS	74,93	79,15	76,98	65,47	62,54	63,97	66,55	65,66	66,10	69,66	76,74	73,03
		Kami	79,12	79,60	79,36	68,09	65,98	67,02	70,23	70,71	70,47	71,66	77,91	74,65
		Δ	+4,19	+0,46	+2,38	+2,62	+3,44	+3,04	+3,68	+5,05	+4,37	+2,00	+1,16	+1,62
	Multi-kata	GTS	56,85	49,26	52,78	52,26	41,27	46,12	50,28	47,34	48,77	56,63	55,29	55,95
		Kami	61,64	55,79	58,57	54,63	44,44	49,02	50,70	57,45	53,87	62,43	63,53	62,97
		Δ	+4,79	+6,53	+5,78	+2,37	+3,17	+2,90	+0,42	+10,11	+5,10	+5,80	+8,24	+7,02

Tabel 4: Analisis dengan mode evaluasi yang berbeda pada tugas ASTE.

Dataset	Model	Target Multi-kata			Opini Multi-kata		
		P.	*R.*	F_1	*P.*	*R.*	F_1
Istirahat 14	GTS	56,54	49,81	52,96	50,67	41,76	45,78
	Kami	65,96	57,62	**61,51**	49,43	47,25	**48,31**
Lap 14	GTS	55,11	44,09	48,99	37,50	26,09	**30,77**
	Kami	56,99	48,18	**52,22**	34,62	26,09	29,75
Sisa 15	GTS	51,09	51,09	51,09	43,40	35,94	39,32
	Kami	55,33	60,58	**57,84**	37,18	45,31	**40,85**
Sisa 16	GTS	62,69	65,12	63,88	28,26	24,07	26,00
	Kami	66,43	72,09	**69,14**	36,73	33,33	**34,95**

Tabel 5: Perbandingan lebih lanjut hasil uji coba antara model kami dan GTS berdasarkan triplet target kata-kata dan opini untuk tugas ASTE.

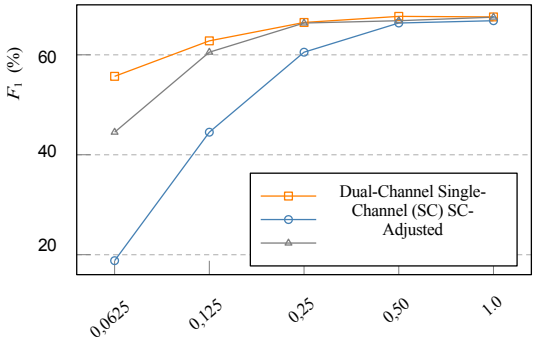

Gambar 3: Hasil dev dengan batas pemangkasan *z*, yang secara intuitif merujuk pada jumlah rentang kandidat yang akan dipertahankan per kata dalam kalimat.

Kata target atau istilah opini multi-kata. Dari Tabel 5, hasil menunjukkan bahwa kinerja lebih rendah ketika triplet mengandung istilah opini multi-kata. Tren ini dapat dikaitkan dengan distribusi data yang tidak seimbang pada triplet yang mengandung kata target atau istilah opini multi-kata.

4.2 Efisiensi Pemangkasan

Untuk menunjukkan efisiensi strategi pemangkasan dual-channel yang diusulkan, kami juga membandingkannya dengan strategi yang lebih sederhana, yang disebut Single-Channel (SC), yang tidak membedakan antara kandidat opini dan target. Gambar 3 menunjukkan perbandingan tersebut. Perhatikan bahwa modul mention dalam strategi ini tidak secara eksplisit menyelesaikan tugas ATE dan OTE, karena hanya memprediksi label mention

m ∈ {*Valid, Invalid*}, di mana *Valid* berarti

span dapat berupa target span atau opinion span, dan

Invalid berarti rentang tersebut tidak termasuk dalam kedua kelompok. Dengan panjang kalimat *n* dan ambang batas pemangkasan *z*, jumlah kandidat dibatasi hingga *nz*, sehingga biaya komputasi berskala dengan jumlah interaksi pasangan, n^2z^2. Strategi dual-channel mempertimbangkan setiap pasangan target-pendapat di mana kumpulan kandidat target dan pendapat yang dipangkas keduanya memiliki *nz* rentang. Perlu dicatat bahwa kedua kumpulan tersebut mungkin berbagi beberapa kandidat. Sebagai perbandingan, strategi saluran tunggal mempertimbangkan setiap

Pasangan target-opini di mana kandidat target dan opini diambil dari kumpulan yang sama dari *nz* spans. Untuk mempertimbangkan setidaknya sebanyak kandidat target dan opini seperti strategi dual-channel, strategi single-channel harus menyesuaikan ambang *batas z* dengan faktor dua, yang mengakibatkan empat kali lebih banyak pasangan dan biaya komputasi. Kami menandai pengaturan ini pada Gambar 3 sebagai SC-Adjusted. Saat mengontrol efisiensi komputasi, terdapat perbedaan kinerja yang signifikan antara Dual-Channel dan Single-Channel dalam $\text{skor}_{F(1)}$, terutama untuk nilai z yang lebih rendah. Meskipun selisih kinerja menyempit seiring peningkatan z, hal ini tidak praktis untuk nilai z yang tinggi. Berdasarkan hasil eksperimen kami, kami memilih strategi pemangkasan dual-channel dengan z = *0.5* untuk model yang dilaporkan.

4.3 Analisis Kualitatif

Untuk memperlihatkan perbedaan antara model-model tersebut, kami menyajikan contoh kalimat dari set data uji ASTE beserta label emasnya, serta prediksi dari GTS (Wu et al., 2020) dan Span-ASTE dalam Gambar 4. Pada contoh pertama, GTS berhasil mengekstrak istilah target *"Windows 8"* yang dipasangkan dengan istilah opini *"tidak menikmati"*, namun sentimennya salah diprediksi sebagai positif. Saat membentuk triplet, heuristik dekodasi mereka mempertimbangkan sentimen inde-

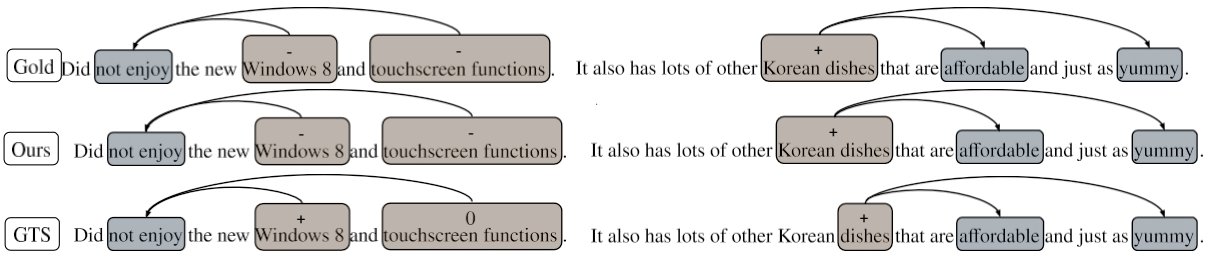

Gambar 4: Analisis kualitatif. Istilah target dan opini ditandai dengan warna oranye dan biru masing-masing. Setiap busur menunjukkan hubungan pasangan antara istilah target dan opini. Polaritas sentimen dari setiap triplet ditunjukkan di atas istilah target.

secara independen untuk setiap pasangan kata: {(*"Windows"*, *"tidak"*, Netral), (*"8"*, *"tidak"*, Netral), (*"Windows"*, *"enjoy"*, Positif), (*"8"*, *"enjoy"*, Positif)}. Heuristik mereka menentukan polaritas sentimen keseluruhan sebagai label yang paling sering muncul di antara pasangan tersebut. Dalam kasus seri (2 netral dan 2 positif), heuristik memiliki bias yang telah ditentukan sebelumnya untuk menetapkan polaritas sentimen ke positif. Demikian pula, metode tingkat kata gagal menangkap sentimen negatif yang diungkapkan oleh *"tidak menikmati"* pada istilah target lain *"fungsi layar sentuh"*. Dalam contoh kedua, metode ini secara tidak lengkap mengekstrak istilah target *"masakan Korea"*, sehingga menghasilkan triplet yang salah. Untuk kedua contoh, metode kami mampu secara akurat mengekstrak pasangan istilah-pendapat dan menentukan sentimen keseluruhan bahkan ketika setiap istilah terdiri dari beberapa kata.

4.4 Studi Ablasi

Kami melakukan studi ablasi untuk menganalisis kinerja berbagai modul dan metode representasi rentang, dan hasilnya ditampilkan dalam Tabel 6. Nilai rata-rata F_1menunjukkan hasil rata-rata dev dari Span-ASTE pada empat dataset benchmark selama 5 kali pengujian. Serupa dengan pengamatan pada resolusi coreference (Lee et al., 2017), kami menemukan bahwa kinerja ASTE menurun saat menghapus lebar rentang dan embedding jarak. Hal ini menunjukkan bahwa informasi posisi masih berguna untuk tugas ASTE, karena target dan opini yang berjauhan atau terlalu panjang kurang mungkin membentuk pasangan rentang yang valid. Seperti yang disebutkan dalam Bagian 2.2.1, kami menjajaki dua metode lain (yaitu, max pooling dan mean pooling) untuk membentuk representasi rentang alih-alih menggabungkan representasi token batas rentang. Hasil negatif menunjukkan bahwa menggunakan pooling untuk mengagregasi representasi rentang merugikan karena kehilangan informasi yang berguna untuk membedakan rentang valid dan tidak valid.

Model	Rata-rata F_1	ΔF_1
Model lengkap	**67,69**	
Tanpa lebar & jarak embedding	66,45	-1,24
Pooling maksimum	66,09	-1,60
rata-rata pooling	66,19	-1,53

Tabel 6: Studi ablasi pada kumpulan data pengembangan.

5 Karya Terkait

Analisis Sentimen merupakan tugas utama dalam Pemahaman Bahasa Alami (NLU) (Wang et al., 2019) dan telah banyak diteliti sebagai masalah klasifikasi pada tingkat kalimat (Raffel et al., 2020; Lan et al., 2020; Yang et al., 2020). Analisis Sentimen Berbasis Aspek (ABSA) (Pontiki dkk., 2014) menangani berbagai tugas analisis sentimen pada tingkat yang lebih detail. Seperti yang disebutkan dalam Bagian 1, subtugas utama meliputi ASC (Dong dkk., 2014; Zhang dkk., 2016; Chen dkk., 2017; He dkk., 2018b; Li dkk., 2018a; Peng dkk., 2018; Wang dan Lu, 2018; He dkk., 2019; Li dan Lu, 2019; Xu dkk., 2020a), ATE (Qiu dkk., 2011; Yin dkk., 2016; Li dkk., 2018b; Ma dkk., 2019), OTE (Hu dan Liu, 2004; Yang dan Cardie, 2012; Klinger dan Cimiano, 2013; Yang dan Cardie, 2013). Ada juga subtask lain yang disebut Target-oriented Opinion Words Extraction (TOWE) (Fan et al., 2019), yang bertujuan untuk mengekstrak kata-kata opini yang sesuai untuk istilah target yang diberikan. Garis penelitian lain berfokus pada penanganan berbagai subtask secara bersamaan. Aspect and Opinion Term Co-Extraction (AOTE) bertujuan untuk mengekstrak aspek dan kata-kata opini secara bersamaan (Wang et al., 2017; Ma et al., 2019; Dai dan Song, 2019) dan sering dianggap sebagai masalah penandaan urutan. Perlu dicatat bahwa AOTE tidak mempertimbangkan hubungan sentimen berpasangan antara setiap istilah target dan istilah opini. End-to-End ABSA (Li dan Lu, 2017; Ma dkk., 2018; Li dkk., 2019; He dkk., 2019) secara bersamaan mengekstrak setiap aspek

Istilah dan sentimen yang terkait dengannya secara end-to-end. Beberapa metode lain baru-baru ini diusulkan untuk menyelesaikan tiga atau lebih subtugas ABSA secara bersamaan. Chen dan Qian (2020) mengusulkan kerangka kerja pembelajaran kolaboratif yang sadar hubungan untuk menyatukan tiga subtugas fundamental dan mencapai kinerja yang kuat pada setiap subtugas dan tugas gabungan. Sementara Wan dkk. (2020) lebih fokus pada subtugas terkait kategori aspek, seperti Ekstraksi Kategori Aspek dan Ekstraksi Bersama Kategori Aspek dan Target. ASTE (Peng dkk., 2019; Wu dkk., 2020; Xu dkk., 2020b; Zhang dkk., 2020) adalah perkembangan terbaru ABSA, dengan tujuan mengekstrak dan membentuk istilah aspek, sentimen terkait, dan istilah pendapat yang sesuai menjadi sebuah triplet.

6 Kesimpulan

Dalam penelitian ini, kami mengusulkan pendekatan tingkat span - Span-ASTE untuk mempelajari interaksi antara span target dan span opini dalam tugas ASTE. Pendekatan ini dapat mengatasi keterbatasan pendekatan existing yang hanya mempertimbangkan interaksi kata-ke-kata. Kami juga mengusulkan untuk memasukkan tugas ATE dan OTE sebagai supervisi untuk strategi pemangkasan dua saluran kami guna mengurangi jumlah kandidat target dan opini yang diidentifikasi, sehingga meningkatkan efisiensi komputasi dan memaksimalkan peluang untuk menggabungkan kandidat target dan opini yang valid. Metode kami secara signifikan outperform metode sebelumnya untuk tugas ASTE, ATE, dan OTE, dan analisis kami menunjukkan keefektifan pendekatan kami. Meskipun kami mencapai kinerja yang kuat pada tugas ASTE, kinerja ini sebagian besar disebabkan oleh perbaikan pada triplet multi-kata. Seperti yang dibahas dalam Bagian 4.1, masih ada kesenjangan kinerja yang signifikan antara triplet kata tunggal dan triplet multi-kata, dan ini dapat menjadi area potensial untuk penelitian di masa depan.

Referensi

Peng Chen, Zhongqian Sun, Lidong Bing, dan Wei Yang. 2017. Jaringan perhatian berulang pada memori untuk analisis sentimen aspek. Dalam *Prosiding EMNLP*.

Zhuang Chen dan Tieyun Qian. 2020. Pembelajaran kolaboratif yang sadar hubungan untuk analisis sentimen berbasis aspek yang terpadu. Dalam *Prosiding ACL*.

Hongliang Dai dan Yangqiu Song. 2019. Ekstraksi istilah aspek dan opini neural dengan aturan yang diekstraksi sebagai pengawasan lemah. Dalam *Prosiding ACL*.

Jacob Devlin, Ming-Wei Chang, Kenton Lee, dan Kristina Toutanova. 2019. BERT: Pra-pelatihan transformator bidireksional dalam jaringan saraf untuk pemahaman bahasa. Dalam *Prosiding NAACL*.

Li Dong, Furu Wei, Chuanqi Tan, Duyu Tang, Ming Zhou, dan Ke Xu. 2014. Jaringan saraf rekursif adaptif untuk klasifikasi sentimen Twitter yang bergantung pada target. Dalam *Prosiding ACL*.

Zhifang Fan, Zhen Wu, Xinyu Dai, Shujian Huang, dan Jiajun Chen. 2019. Ekstraksi kata-kata opini berorientasi target dengan penandaan urutan neural yang terintegrasi target. Dalam *Prosiding NAACL*.

Matt Gardner, Joel Grus, Mark Neumann, Oyvind Tafjord, Pradeep Dasigi, Nelson F. Liu, Matthew Peters, Michael Schmitz, dan Luke S. Zettlemoyer. 2017. Allennlp: Platform Pemrosesan Bahasa Alami Semantik Mendalam.

Luheng He, Kenton Lee, Omer Levy, dan Luke Zettlemoyer. 2018a. Prediksi Bersama Predikat dan Argumen dalam Labeling Peran Semantik Neural. Dalam *Prosiding ACL*.

Ruidan He, Wee Sun Lee, Hwee Tou Ng, dan Daniel Dahlmeier. 2018b. Model perhatian yang efektif untuk klasifikasi sentimen tingkat aspek. Dalam *Prosiding COLING*.

Ruidan He, Wee Sun Lee, Hwee Tou Ng, dan Daniel Dahlmeier. 2019. Jaringan pembelajaran multi-tugas interaktif untuk analisis sentimen berbasis aspek end-to-end. Dalam *Prosiding ACL*.

Sepp Hochreiter dan Ju¨rgen Schmidhuber. 1997. Long short-term memory. *Neural computation*, 9:1735–80.

Min*q*ing Hu dan Bing Liu. 2004. Penambangan dan ringkasan ulasan pelanggan. Dalam *Prosiding ACM SIGKDD*.

R. Klinger dan P. Cimiano. 2013. Model probabilistik gabungan dan pipa untuk analisis sentimen beresolusi tinggi: Mengekstrak aspek, frasa subjektif, dan hubungan di antara mereka. Dalam *Konferensi Internasional IEEE ke-13 tentang Data Mining Workshops 2013*.

Zhenzhong Lan, Mingda Chen, Sebastian Goodman, Kevin Gimpel, Piyush Sharma, dan Radu Soricut. 2020. Albert: Sebuah versi ringan BERT untuk pembelajaran mandiri representasi bahasa. Dalam *Prosiding ICLR*.

Kenton Lee, Luheng He, Mike Lewis, dan Luke Zettlemoyer. 2017. Resolusi referensi end-to-end berbasis jaringan saraf. Dalam *Prosiding EMNLP*.

Hao Li dan Wei Lu. 2017. Pembelajaran lingkup sentimen laten untuk analisis sentimen tingkat entitas. Dalam *Prosiding AAAI*.

Hao Li dan Wei Lu. 2019. Pembelajaran struktur eksplisit dan implisit untuk analisis sentimen yang ditargetkan. Dalam *Prosiding EMNLP*.

Xin Li, Lidong Bing, Wai Lam, dan Bei Shi. 2018a. Jaringan transformasi untuk klasifikasi sentimen berorientasi target. Dalam *Prosiding ACL*.

Xin Li, Lidong Bing, Piji Li, dan Wai Lam. 2019. Model terpadu untuk ekstraksi target opini dan prediksi sentimen target. Dalam *Prosiding AAAI*.

Xin Li, Lidong Bing, Piji Li, Wai Lam, dan Zhimou Yang. 2018b. Ekstraksi istilah aspek dengan perhatian sejarah dan transformasi selektif. Dalam *Prosiding IJCAI*.

Bing Liu. 2012. Analisis sentimen dan penambangan opini. *Synthesis Lectures on Human Language Technologies*, 5(1):1–167.

Yi Luan, Dave Wadden, Luheng He, Amy Shah, Mari Ostendorf, dan Hannaneh Hajishirzi. 2019. Kerangka kerja umum untuk ekstraksi informasi menggunakan grafik rentang dinamis. Dalam *Prosiding NAACL*.

Dehong Ma, Sujian Li, dan Houfeng Wang. 2018. Pembelajaran Bersama untuk Analisis Sentimen yang Ditargetkan. Dalam *Prosiding EMNLP*.

Dehong Ma, Sujian Li, Fangzhao Wu, Xing Xie, dan Houfeng Wang. 2019. Menjelajahi pembelajaran urutan-ke-urutan dalam ekstraksi istilah aspek. Dalam *Prosiding ACL*.

Haiyun Peng, Yukun Ma, Yang Li, dan Erik Cam-bria. 2018. Pembelajaran urutan target aspek multi-tingkat untuk analisis sentimen bahasa Tionghoa. *Knowledge-Based Systems*, 148:167–176.

Haiyun Peng, Lu Xu, Lidong Bing, Fei Huang, Wei Lu, dan Luo Si. 2019. Mengetahui apa, bagaimana, dan mengapa: Solusi hampir lengkap untuk analisis sentimen berbasis aspek. Dalam *Prosiding AAAI*.

Jeffrey Pennington, Richard Socher, dan Christopher D. Manning. 2014. GLOVE: Vektor global untuk representasi kata. Dalam *Prosiding EMNLP*.

Maria Pontiki, Dimitris Galanis, Haris Papageorgiou, Ion Androutsopoulos, Suresh Manandhar, Mohammed AL-Smadi, Mahmoud Al-Ayyoub, Yanyan Zhao, Bing Qin, Orphee De Clercq, dkk. 2016. Semeval-2016 Tugas 5: Analisis Sentimen Berbasis Aspek. Dalam *Prosiding SemEval*.

Maria Pontiki, Dimitris Galanis, Haris Papageorgiou, Suresh Manandhar, dan Ion Androutsopoulos. 2015. SemEval-2015 Tugas 12: Analisis Sentimen Berbasis Aspek. Dalam *Prosiding SemEval*.

Maria Pontiki, Dimitris Galanis, John Pavlopoulos, Harris Papageorgiou, Ion Androutsopoulos, dan Suresh Manandhar. 2014. Semeval-2014 Tugas 4: Analisis Sentimen Berbasis Aspek. Dalam *Prosiding SemEval*.

Guang Qiu, Bing Liu, Jiajun Bu, dan Chun Chen. 2011. Perluasan kata opini dan ekstraksi target melalui propagasi ganda. *Computational Linguistics*, 37(1):9–27.

Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, dan Peter J. Liu. 2020. Menjelajahi batas-batas pembelajaran transfer dengan transformer teks-ke-teks yang terpadu. *Jurnal Penelitian Pembelajaran Mesin*, 21(140):1–67.

Jialong Tang, Ziyao Lu, Jinsong Su, Yubin Ge, Linfeng Song, Le Sun, dan Jiebo Luo. 2019. Pembelajaran perhatian self-supervised progresif untuk analisis sentimen tingkat aspek. Dalam *Prosiding ACL*.

David Wadden, Ulme Wennberg, Yi Luan, dan Han-naneh Hajishirzi. 2019. Ekstraksi entitas, hubungan, dan peristiwa dengan representasi rentang yang dikontekstualisasikan. Dalam *Prosiding EMNLP*.

Hai Wan, Yufei Yang, Jianfeng Du, Yanan Liu, Kunxun Qi, dan Jeff Z. Pan. 2020. Deteksi Bersama Target-Aspek-Sentimen untuk Analisis Sentimen Berbasis Aspek. Dalam *Prosiding AAAI*.

Alex Wang, Amanpreet Singh, Julian Michael, Felix Hill, Omer Levy, dan Samuel Bowman. 2019. GLUE: Platform benchmark dan analisis multi-tugas untuk pemahaman bahasa alami. Dalam *Prosiding ICLR*.

Bailin Wang dan Wei Lu. 2018. Pembelajaran opini laten untuk klasifikasi sentimen tingkat aspek. Dalam *Prosiding AAAI*.

Wenya Wang, Sinno Jialin Pan, Daniel Dahlmeier, dan Xiaokui Xiao. 2017. Perhatian multi-lapis terintegrasi untuk ekstraksi bersamaan istilah aspek dan opini. Dalam *Prosiding AAAI*.

Zhen Wu, Chengcan Ying, Fei Zhao, Zhifang Fan, Xinyu Dai, dan Rui Xia. 2020. Skema penandaan grid untuk ekstraksi opini berorientasi aspek dengan tingkat detail tinggi. Dalam *Temuan EMNLP*.

Lu Xu, Lidong Bing, Wei Lu, dan Fei Huang. 2020a. Klasifikasi sentimen aspek dengan rentang opini spesifik aspek. Dalam *Prosiding EMNLP*.

Lu Xu, Hao Li, W. Lu, dan Lidong Bing. 2020b. Penandaan yang sadar posisi untuk ekstraksi triplet sentimen aspek. Dalam *Prosiding EMNLP*.

Bishan Yang dan Claire Cardie. 2012. Ekstraksi ekspresi opini dengan bidang acak kondisional semi-Markov. Dalam *Prosiding EMNLP*.

Bishan Yang dan Claire Cardie. 2013. Inferensi Bersama untuk Ekstraksi Opini Berbasis Detail. Dalam *Prosiding ACL*.

Min Yang, Wenting Tu, Jingxuan Wang, Fei Xu, dan Xiaojun Chen. 2017. LSTM berbasis perhatian untuk klasifikasi sentimen bergantung target. Dalam *Prosiding AAAI*.

Zhilin Yang, Zihang Dai, Yiming Yang, Jaime Car-bonell, Ruslan Salakhutdinov, dan Quoc V. Le. 2020. Xlnet: Pelatihan pra-pelatihan autoregresif umum untuk pemahaman bahasa. Dalam *Prosiding NeurIPS*.

Yichun Yin, Furu Wei, Li Dong, Kaimeng Xu, Ming Zhang, dan Ming Zhou. 2016. Embedding kata dan jalur ketergantungan tanpa pengawasan untuk ekstraksi istilah aspek. Dalam *Prosiding IJCAI*.

Chen Zhang, Qiuchi Li, Dawei Song, dan Benyou Wang. 2020. Kerangka kerja pembelajaran multi-tugas untuk ekstraksi triplet opini. Dalam *Temuan EMNLP*.

Meishan Zhang, Yue Zhang, dan Duy-Tin Vo. 2016. Jaringan saraf terkendali untuk analisis sentimen yang ditargetkan. Dalam *Prosiding AAAI*.

A Pengaturan Eksperimen Tambahan

Kami menjalankan eksperimen model kami pada GPU Nvidia Tesla V100, dengan versi CUDA 10.2 dan PyTorch 1.6.0. Waktu eksekusi rata-rata untuk BERT-berbasis model adalah 157 detik/epoch, 115 detik/epoch, 87 sec/epoch, dan 111 sec/epoch untuk Rest 14, Lap 14, Rest 15, dan Rest 16 masing-masing. Jumlah parameter total adalah 2,24 juta saat menggunakan GloVe, dan 110 juta saat menggunakan BERT base. Jaringan saraf feed-forward dalam modul mention dan modul triplet memiliki 2 lapisan tersembunyi dengan ukuran tersembunyi 150. Kami menggunakan aktivasi ReLU dan dropout sebesar 0,4 setelah setiap lapisan tersembunyi. Kami menggunakan inisialisasi bobot Xavier Normal untuk parameter feed-forward. Embedding lebar rentang dan jarak memiliki dimensi 20 dan 128 masing-masing. Nilai masukan mereka di-bucket (Gardner et al., 2017) sebelum dimasukkan ke dalam pencarian matriks embedding: [0, 1, 2, 3, 4, 5-7, 8-15, 16-31, 32-63, 64+]. Selama pelatihan, parameter model diperbarui setelah setiap kalimat, yang menghasilkan ukuran batch sebesar 1. Untuk setiap urutan teks masukan, kami membatasinya hingga maksimum 512 token.

B Statistik Data Tambahan

Tabel 9 menunjukkan jumlah istilah target dan istilah opini pada empat dataset.

C Hasil Pengembangan

Tabel 10 menunjukkan hasil model kami pada dataset pengembangan.

D Perbandingan Tambahan

Seperti yang disebutkan dalam catatan kaki 5 pada Bagian 3.5, kami tidak dapat melakukan perbandingan langsung dengan model JET (Xu et al., 2020b), karena model tersebut tidak dapat secara langsung menyelesaikan tugas ATE dan OTE kecuali evaluasi dilakukan berdasarkan hasil triplet. Tabel 7 menunjukkan perbandingan semacam itu. Metode yang kami usulkan

Dataset	Model	ATE			OTE		
		P.	*R.*	F_1	*P.*	*R.*	F_1
Istirahat 14	$\text{JET}^{o}_{M=6}$	83,21	66,04	73,64	83,76	77,28	80,39
	GTS	83,25	81,49	82,36	86,55	86,65	**86,60**
	Kami	86,20	80,31	**83,15**	87,20	84,54	85,85
Lap 14	$\text{JET}^{M=6}$	83,33	68,03	74,91	77,16	75,53	76,34
	GTS	82,17	73,65	77,68	81,63	74,05	77,66
	Kami	87,69	75,38	**81,07**	85,61	76,58	**80,84**
Istirahat 15	$\text{JET}^{M=6}$	83,04	65,74	73,38	81,33	68,98	74,65
	GTS	80,95	74,77	77,74	80,96	76,57	78,70
	Kami	81,60	78,01	**79,76**	80,09	81,13	**80,61**
Istirahat 16	$\text{JET}^{o\ M=6}$	83,33	68,58	75,24	89,44	80,21	84,57
	GTS	82,69	85,62	84,13	83,37	86,53	84,92
	Kami	84,20	86,06	**85,12**	84,62	88,00	**86,28**

Tabel 7: Hasil pengujian pada tugas ATE dan OTE dengan metode evaluasi sub-optimal. Metode kami dan GTS (Wu et al., 2020) memungkinkan tugas ATE dan OTE diprediksi secara independen dari tugas ASTE. Namun, $\text{JET}^{M=6}$ (Xu et al., 2020b) tidak. Oleh karena itu, kami membuat perbandingan lain di sini dengan mengekstrak semua rentang opini dan target dari prediksi ASTE.

Dataset	Model	ATE			OTE		
		P.	*R.*	F_1	*P.*	*R.*	F_1
Sisa 14	GTS	78,50	87,38	82,70	82,07	88,99	85,39
	RACL	79,90	87,74	83,63	80,26	87,99	83,94
	Kami	83,56	87,59	**85,50**	82,93	89,67	**86,16**
Lap 14	GTS	78,63	81,86	80,21	76,27	79,32	77,77
	RACL	78,11	81,99	79,99	75,12	79,92	77,43
	Kami	81,48	86,39	**83,86**	83,00	82,28	**82,63**
Istirahat 15	GTS	74,95	82,41	78,50	74,75	81,56	78,01
	RACL	75,22	81,94	78,43	76,41	82,56	79,35
	Kami	78,97	84,68	**81,72**	77,36	84,86	**80,93**
Istirahat 16	GTS	75,05	89,16	81,50	78,36	88,42	83,09
	RACL	74,12	89,20	80,95	79,25	89,77	84,17
	Kami	79,78	88,50	**83,89**	82,59	90,91	**86,54**

Tabel 8: Perbandingan tambahan hasil uji pada tugas ATE dan OTE. Perlu dicatat bahwa RACL (Chen dan Qian, 2020) tidak mempertimbangkan supervisi dari pasangan target-opini, tetapi termasuk polaritas sentimen pada istilah target.

secara umum outperforms dua pendekatan end-to-end sebelumnya pada empat dataset.

Seperti yang disebutkan dalam Tabel 3, sulit untuk melakukan perbandingan yang adil antara kerangka kerja ABSA sebelumnya RACL (Chen dan Qian, 2020), yang juga menangani tugas ATE dan OTE sambil menyelesaikan subtugas ABSA lainnya, dengan pendekatan kami serta GTS (Wu dkk., 2020). Hal ini karena pendekatan yang disebutkan memiliki pengaturan tugas yang berbeda. RACL mempertimbangkan polaritas sentimen pada istilah target saat menyelesaikan tugas ATE dan OTE, tetapi GTS dan metode kami keduanya mempertimbangkan hubungan pasangan antara istilah target dan istilah opini. Namun, sebagai referensi, Tabel 8 menunjukkan perbandingan-

Dataset	Istirahat 14		Lap 14		Rest 15		Rest 16	
	# Target	# Pendapat	# Target	# Pendapat	# Target	# Pendapat	# Target	# Pendapat
Kereta	2051	2086	1281	1268	862	941	1198	1307
Dev	500	503	296	304	213	236	296	319
Uji	848	854	463	474	432	461	452	475

Tabel 9: Statistik tambahan. # Target menunjukkan jumlah istilah target. # Opini menunjukkan jumlah istilah opini.

Model	Istirahat 14			Putaran 14			Istirahat 15			Istirahat 16		
	P.	*R.*	F_1	*P.*	*R.*	F_1	*P.*	*R.*	F_1	*P.*	*R.*	F_1
Kami (BiLSTM)	66,76	53,90	59,61	60,78	49,37	54,45	69,13	60,08	64,26	71,59	61,95	66,41
Kami (BERT)	68,05	65,65	66,80	63,35	58,90	61,02	70,16	71,41	70,75	72,52	71,92	72,19

Tabel 10: Hasil pada dataset pengembangan.

Perbandingan ketiga metode pada tugas ATE dan OTE pada dataset yang dirilis oleh Xu et al. (2020b).